CebadaVision: predicción del rendimiento de cebada de temporal en Hidalgo, Tlaxcala y Puebla

Reto AgroCebada 2026 (FIRA) · Equipo CebadaVision · Octubre de 2026

1. Introducción

La cebada es uno de los cultivos más importantes del Altiplano central de México y la materia prima de la industria cervecera. Cerca de tres cuartas partes de la superficie nacional se siembra en esta región, casi toda de temporal, y Hidalgo, Puebla y Tlaxcala concentran la mayor parte de la producción (SIAP, 2023). Quienes la cultivan son, en su mayoría, pequeños y medianos productores que venden su cosecha a comercializadoras y parafinancieras. Para ellos, el rendimiento por hectárea define al mismo tiempo cuánto ganan y si podrán pagar el crédito de avío con el que financiaron el ciclo.

Saber cuánto va a rendir una parcela sin visitarla, y para todas las parcelas de una región, es un problema abierto con valor público directo. Los satélites lo hacen posible: Sentinel-2 pasa cada cinco días con píxeles de 10 m y constelaciones como Planet observan casi a diario con píxeles de 3 m. Los estudios recientes muestran que los modelos de aprendizaje automático que combinan estas series con clima y relieve explican buena parte de la variación del rendimiento en cultivos de temporal (van Klompenburg et al., 2020; de la Fuente et al., 2023), aunque su desempeño depende de cuántas parcelas se tengan, de qué tan confiable sea el dato de rendimiento y de cómo estén repartidas.

El Reto AgroCebada 2026 plantea exactamente ese problema con datos reales: 197 parcelas de cebada de temporal del ciclo abril–octubre de 2025 en Hidalgo, Tlaxcala y Puebla, con índices de vegetación de Sentinel-2, Landsat y Planet, precipitación y temperatura mensuales, elevación y pendiente. El rendimiento de grano (toneladas por hectárea) se conoce para 138 parcelas; el de las otras 59 lo guarda el comité para calificar las predicciones. Ese rendimiento viene, en la mayoría de los casos, del registro de compra de la comercializadora, no de una medición en campo, así que trae ruido y, en algunas zonas, está redondeado a medias toneladas.

Este trabajo presenta CebadaVision, una solución con tres partes. Primero, una tabla de variables por parcela que resume cómo se comportó cada índice durante el ciclo (cuándo emergió el cultivo, cuánto verdor alcanzó, cuánto duró verde y qué tan rápido se secó), más clima, relieve y ubicación. Segundo, un modelo que promedia dos algoritmos de árboles (LightGBM y Random Forest), validado con un esquema repetido y estratificado por estado, que alcanza un error (RMSE) de 0.49 t/ha frente a 0.85 t/ha de predecir el promedio regional. Tercero, una aplicación web que ejecuta el modelo, muestra las 197 parcelas en un mapa, entrega la estimación con su rango y explica con palabras sencillas cómo se llegó a cada número.

El análisis exploratorio reveló un hecho que ordena todo el trabajo: la ubicación de la parcela explica cerca de dos tercios de la variación del rendimiento. Las tres zonas del estudio rinden distinto (alrededor de 4.5 t/ha en el este de Puebla, 3.0 en el suroeste de Tlaxcala y 3.3 en el norte de Hidalgo) y las parcelas vecinas

comparten suelo, clima y manejo. Por eso el modelo usa de forma explícita la información espacial y mide lo que aportan los índices satelitales, el clima y el relieve *dentro* de esa estructura. Ese mismo marco es el que usamos para responder las tres preguntas guía del reto.

2. Justificación

FIRA y los intermediarios financieros rurales otorgan crédito de avío a productores de cebada sin una medida objetiva, oportuna y barata del rendimiento que puede dar cada parcela. Esa falta encarece el crédito, deja fuera a quienes no tienen historial y dificulta diseñar seguros ligados a la producción. Un modelo que estime el rendimiento de cualquier parcela georreferenciada a partir de datos satelitales y climáticos públicos, con un error conocido, convierte información que ya existe en un insumo para decidir.

El reto aporta además un caso poco común: datos reales de 197 parcelas con rendimiento comercial, no datos sintéticos ni de estación experimental. Resolverlo con rigor —validación reproducible, incertidumbre cuantificada y una explicación de cada predicción— es lo que hace creíble la herramienta tanto para el analista de crédito como para el productor, que fue el público prioritario señalado por FIRA en las sesiones de dudas.

3. Objetivos

Objetivo general. Predecir el rendimiento de grano (t/ha) de parcelas de cebada de temporal del ciclo abril–octubre de 2025 en Hidalgo, Tlaxcala y Puebla, a partir de índices de vegetación satelitales, clima, relieve y ubicación, y entregar las predicciones de las 59 parcelas sin dato con un error cuantificado.

Objetivos específicos.

1. Construir una tabla reproducible de variables por parcela que resuma la fenología de los índices de Planet y Sentinel-2 (valores por mes, emergencia, máximo, duración, velocidad de secado), el clima del ciclo, el relieve y la ubicación.
2. Comparar modelos (Ridge, Random Forest, LightGBM, proceso gaussiano y ensambles) con un mismo esquema de validación cruzada repetida y estratificada por estado, más una validación agrupada por municipio, usando como referencia el promedio regional (RMSE 0.851) y un kNN espacial.
3. Responder con evidencia las tres preguntas guía: qué índice de vegetación pesa más, qué variable climática tiene mayor peso y qué combinación de variables funciona mejor.
4. Poner el modelo al alcance de analistas y productores en una aplicación web que lo ejecute, muestre mapa, rango de predicción y una explicación sencilla por parcela, y discutir su uso en inclusión financiera.

4. Metodología

Datos. Usamos únicamente el dataset oficial: 197 polígonos (138 de entrenamiento y 59 por predecir), 47 804 observaciones de Planet (NDVI, EVI, LAI, MSAVI) de 2025, 107 666 de Sentinel-2 y Landsat de 2022 a

2025 (22 índices), rásteres mensuales de precipitación (CHIRPS) y de temperatura mínima y máxima a unos 5 km, y elevación y pendiente del Continuo de Elevaciones Mexicano. Una auditoría confirmó 197 identificadores únicos en todas las fuentes, la unión sin pérdidas entre shapefile y tablas, y el reparto 138/59. Trabajamos con el ciclo abril–octubre de 2025 (más noviembre, para ver el secado). Las observaciones con nubosidad del 100 % se descartaron porque traen los índices vacíos; no se rellenó ninguna. Landsat no aporta índices en 2025.

Variables. Para cada parcela e índice tomamos la serie del promedio del polígono, la suavizamos con una mediana móvil de tres observaciones y calculamos: mediana de cada mes de abril a noviembre, medianas por ventana (mayo–junio, julio–septiembre, octubre–noviembre), valor y fecha del máximo, amplitud, área bajo la curva de abril a octubre, inicio y fin de la temporada verde (cuando la curva cruza la mitad de su amplitud al subir y al bajar), duración y velocidades de crecimiento y de secado. Resultaron 80 variables de Planet y 160 de Sentinel-2 (NDVI, EVI, SAVI, LAI, fAPAR, NDWI, MSI, NDTI). El clima se resumió en lluvia acumulada abril–octubre, temperaturas mínima y máxima medias del ciclo y anomalía de lluvia respecto al promedio 2022–2024; por la resolución del ráster, estas variables solo toman 25 valores distintos en las 197 parcelas. El relieve aporta elevación media, su variación y pendiente media. La ubicación se representó con las coordenadas del centroide (EPSG:6372, en km), la zona (k-means de tres grupos sobre los centroides, sin usar el rendimiento), el rendimiento promedio de la zona y el promedio, ponderado por distancia, del rendimiento de las ocho parcelas de entrenamiento más cercanas.

Validación. La métrica principal es el RMSE (criterio de FIRA), con MAE y R^2. Usamos validación cruzada de 5 particiones estratificadas por estado —imita el reparto oficial 70/30, proporcional por zona y espacialmente mezclado— repetida 10 veces con semillas distintas; reportamos promedio y desviación entre repeticiones, y tratamos como ruido cualquier diferencia de RMSE menor a 0.03 t/ha. Como prueba más exigente añadimos una validación agrupada por municipio. Las variables de vecinos y de zona se recalculan dentro de cada partición solo con las parcelas de entrenamiento de esa partición (y sin contar a la propia parcela), de modo que el rendimiento de una parcela nunca entra en sus propias variables ni en las de las parcelas con las que se evalúa.

Modelos. Comparamos regresión ridge, Random Forest (400 árboles, hoja mínima de 3, 33 % de variables por partición), un LightGBM pequeño (300 árboles, tasa 0.03, 7 hojas, submuestreo, regularización L2) y un proceso gaussiano con núcleo RBF más ruido; los faltantes se rellenan con la mediana de entrenamiento dentro de cada ajuste. El banco de experimentos evaluó cada grupo de variables por separado, la ubicación más cada grupo, combinaciones completas y ensambles por promedio. Para las preguntas guía evaluamos cada índice con sus variables fenológicas y cada variable climática, solos y con la ubicación fija, calculamos la importancia por permutación del modelo final (cuánto sube el RMSE al barajar cada variable) y una ablación por grupos.

Modelo final. Es el promedio de dos modelos: LightGBM con ubicación, relieve y clima (11 variables) y Random Forest con ubicación, fenología de Planet, clima y relieve (91 variables). La predicción se recorta al rango plausible de 1.5 a 6.5 t/ha. El rango de predicción al 80 % se calcula como ±1.28 veces el RMSE de validación. La explicación de cada parcela usa valores SHAP (Lundberg y Lee, 2017) promediados entre

ambos modelos, agrupados por tipo de variable y traducidos a una nota en lenguaje sencillo. Para que la aplicación ejecute el modelo en el navegador ajustamos una regresión ridge sustituta sobre 11 variables interpretables y reportamos cuánto difiere del ensamble.

Implementación. Python 3.13 (pandas, geopandas, rasterio, scikit-learn, LightGBM, SHAP); aplicación en React, TypeScript, Leaflet y Recharts; scripts documentados en el README.

5. Resultados y discusión

Puntos de referencia. Predecir el promedio de entrenamiento da RMSE 0.851 t/ha (R^2 −0.02). Un kNN espacial que solo mira a las ocho parcelas vecinas baja a 0.501 (R^2 0.65): la ubicación sola explica cerca de dos tercios de la variación y es la vara real que cualquier modelo debía superar.

Cada grupo de variables por separado (CV 5×10, LightGBM). Solo coordenadas: 0.507; solo vecinos: 0.502; solo clima: 0.545; solo fenología de Planet: 0.625; solo Sentinel-2: 0.636; solo estadísticos simples de Planet (media, desviación, máximo, mínimo): 0.784; solo relieve: 0.762. La fenología completa vale mucho más que los estadísticos simples, porque la señal agronómica está al inicio del ciclo y en el secado, no en el máximo, que se satura en agosto–septiembre. Y el clima "predice" bien aunque solo tenga 25 valores distintos: funciona como etiqueta de zona.

Ubicación más cada grupo. Sumar a la ubicación los índices de Planet, Sentinel-2 o el clima deja el RMSE entre 0.500 y 0.515; sumar relieve lo lleva a 0.492. Ningún grupo aporta más de 0.01–0.02 t/ha una vez conocida la ubicación: la correlación de cualquier variable satelital con lo que el kNN no explica no pasa de $|\rho| = 0.17$. Con 138 parcelas y un rendimiento comercial, redondeado a medias toneladas en toda la zona de Tlaxcala, el piso de ruido es alto. Los modelos lineales empeoran al agregar variables (ridge con 251 variables: 0.567); los de árboles se mantienen.

Modelo final. El ensamble LightGBM (ubicación, relieve, clima) + Random Forest (ubicación, fenología Planet, clima, relieve) obtiene RMSE 0.491 ± 0.007, MAE 0.336 y R^2 0.664. En la validación agrupada por municipio da RMSE 0.574 frente a 0.708 del kNN puro: las variables satelitales, climáticas y de relieve sí ayudan cuando hay que extrapolar a municipios no vistos. Por estado, el RMSE es 0.357 en Hidalgo, 0.375 en Tlaxcala y 0.578 en Puebla, donde el rendimiento es más alto y más variable (≈4.5 ± 0.5 t/ha): el modelo acierta el nivel de cada zona, pero explica poco de la variación dentro de Puebla. Las 59 predicciones tienen promedio 3.95 t/ha y van de 2.88 a 4.65, en línea con el entrenamiento: 4.47 en Puebla, 3.79 en Hidalgo y 3.00 en Tlaxcala. Frente al Ridge provisional de nueve variables (0.551) la mejora es de 0.06 t/ha; frente al promedio, 0.36.

Pregunta 1: ¿qué índice es más importante? El EVI de Planet. Con los mismos folds, cada índice solo con sus variables fenológicas da RMSE 0.639 (EVI), 0.655 (MSAVI), 0.678 (NDVI) y 0.685 (LAI); en Sentinel-2 los mejores son LAI y SAVI (0.660) y el peor NDTI (0.733). La importancia por permutación del modelo final mantiene el orden EVI > MSAVI > NDVI > LAI; las variables de EVI que más pesan son la mediana de mayo–junio (emergencia) y la velocidad de secado. EVI se satura menos que NDVI cuando el cultivo cubre todo el suelo y es menos sensible al fondo (Huete et al., 2002).

Pregunta 2: ¿qué variable climática pesa más? La precipitación del ciclo. Sola, la anomalía de lluvia respecto a 2022–2024 es la que más explica (RMSE 0.584), seguida de la temperatura mínima (0.603), la lluvia acumulada (0.604) y la temperatura máxima (0.658). 2025 fue más lluvioso que el promedio 2022–2024 en todas las parcelas (de +202 a +574 mm) y las parcelas con mayor exceso de lluvia rindieron menos. Con la ubicación fija, ninguna variable climática agrega más de 0.01 t/ha, y dentro del modelo final la temperatura mínima es la que más mueve la predicción; ambas lecturas están limitadas por los 5 km de resolución del clima.

Pregunta 3: ¿qué combinación funciona mejor? Ubicación + relieve + clima + fenología de Planet (RMSE 0.494 en la ablación), seguida de ubicación + relieve (0.496); la mejor sin ubicación es índices + clima + relieve (0.538) y la peor, solo relieve (0.754). Sumar Sentinel-2 a Planet no mejora (0.507–0.520): ven la misma fenología y Planet, casi diario, la describe mejor. La mejor combinación es poca información complementaria: la ubicación da el nivel, relieve y clima afinan la zona, la fenología explica diferencias dentro de ella.

Discusión. En esta muestra la predicción espacial domina y los índices afinan en el margen; es una limitación del dato (138 parcelas, rendimiento comercial con redondeo, 25 píxeles de clima), no del método. Las predicciones son estables (desviación entre repeticiones de 0.007 t/ha), pero su rango al 80 % es de ±0.63 t/ha, y la aplicación lo muestra junto a cada estimación.

6. Uso de la ciencia de datos en la inclusión financiera del sector agro

Hoy el crédito de avío a pequeños productores de cebada se decide con información desigual: el intermediario financiero conoce el historial del productor, si lo hay, pero no el potencial productivo de la parcela concreta que respaldará el pago. CebadaVision convierte datos públicos —imágenes satelitales, clima, relieve y la ubicación de la parcela— en una estimación de rendimiento por parcela con error conocido, sin visita de campo y actualizable cada ciclo. Eso cambia tres decisiones.

Primera, el tamaño del crédito. Con rendimiento esperado, superficie y precio de referencia se obtiene el valor esperado de la cosecha y, con el rango del modelo, un escenario conservador; el monto de avío puede ajustarse a lo que esa parcela puede pagar, no a un promedio regional. La aplicación muestra la producción estimada en toneladas y un semáforo bajo/medio/alto por terciles, pensado como primer filtro de riesgo.

Segunda, la inclusión de productores sin historial. Alguien sin expediente crediticio puede ser evaluado por la evidencia objetiva de su parcela y de sus vecinas; la ubicación, que es lo que más pesa en el modelo, es justamente información que el productor no puede alterar y que la financiera no necesita verificar en campo.

Tercera, el diseño de seguros y garantías. El error por zona (0.36 t/ha en Hidalgo y Tlaxcala, 0.58 en Puebla) y la trayectoria del vigor del cultivo durante el ciclo permiten detectar a tiempo desviaciones respecto a lo esperado y activar seguros paramétricos o reestructuras antes de la cosecha.

Para que esto sea inclusión y no exclusión hace falta transparencia: cada estimación se entrega con su rango y con una explicación sencilla de qué la subió o la bajó, para que el productor pueda entenderla, cuestionarla y usarla en su propia negociación con la comercializadora o la financiera.

7. Conclusiones

Construimos un modelo reproducible que predice el rendimiento de grano de parcelas de cebada de temporal en Hidalgo, Tlaxcala y Puebla con RMSE de 0.491 ± 0.007 t/ha, MAE de 0.336 y R^2 de 0.664 en validación cruzada estratificada por estado y repetida diez veces, frente a 0.851 del promedio regional y 0.501 de un kNN espacial. El modelo final es un ensamble de LightGBM y Random Forest sobre ubicación, relieve, clima y fenología de Planet, y entrega las 59 predicciones solicitadas con promedio de 3.95 t/ha y un rango al 80 % de ±0.63 t/ha.

El hallazgo principal es estructural: la ubicación de la parcela explica cerca de dos tercios de la variación del rendimiento, porque las tres zonas rinden distinto y porque parcelas vecinas comparten suelo, clima y manejo. Un modelo que ignore esto subestima su error o atribuye a los índices satelitales un mérito que pertenece a la geografía. Evaluar las variables dentro de esa estructura permitió responder las preguntas guía con evidencia comparable: el índice más importante es el EVI de Planet, por su señal en la emergencia y en el secado; la variable climática con mayor peso es la precipitación del ciclo, en particular su anomalía respecto a 2022–2024; y la mejor combinación es ubicación + relieve + clima + fenología de Planet; sumar Sentinel-2 no mejora.

Las limitaciones se declaran en la aplicación: rendimiento de origen comercial, redondeado en una zona; clima a 5 km con solo 25 valores distintos; 138 parcelas de un solo ciclo; variedad, fecha de siembra, dosis y siniestros desconocidos. Por eso el aporte de los índices sobre la ubicación es pequeño, aunque mejora la extrapolación a municipios no vistos.

La aplicación CebadaVision ejecuta el modelo en el navegador, muestra las 197 parcelas en un mapa, permite buscar cada una por su identificador, presenta la estimación con rango y semáforo, explica con palabras sencillas cómo se llegó al número y ofrece un simulador y la descarga del CSV, con prioridad en el productor.

Como siguiente paso, el mismo pipeline se extendería a varios ciclos y a rendimientos medidos en campo, para modelar con la fenología lo que la ubicación no explica, estimar antes de la cosecha y calibrar el rango por zona. Con FIRA, el modelo podría integrarse a la originación de crédito de avío como variable objetiva de capacidad productiva por parcela.